Détection des maladies de la tomate par CNN :
du laboratoire (PlantVillage) au terrain (PlantDoc)

Rapport technique | Module Deep Learning, cohorte 3 AI hub | Groupe : Aminata Mbengue | 10/11/2026

Notebook et dépôt GitHub : https://github.com/aminata-mbengue/detection-maladies-tomate

1. Contexte et problème

Une coopérative agricole souhaite fournir à ses agriculteurs un outil simple : photographier une feuille de tomate avec un smartphone et obtenir un diagnostic préliminaire. Le défi n'est pas d'atteindre un score élevé sur un jeu de données propre, mais de savoir si un modèle fonctionne réellement dans un champ. Nous mesurons donc l'écart entre des photos de laboratoire (PlantVillage, fond uniforme) et des photos de terrain (PlantDoc, fonds chargés, lumière variable), puis nous testons des stratégies pour le réduire.

Nous avons choisi la **tomate**, présente dans les deux jeux. Les classes retenues sont celles communes à PlantVillage, au train PlantDoc et au test PlantDoc : **8 classes** (saine, tache bactérienne, alternariose, mildiou, moisissure des feuilles, mosaïque, septoriose, virus des feuilles jaunes en cuillère). La « target spot » est absente de PlantDoc et les acariens n'apparaissent pas dans l'intersection des trois jeux : ces deux classes sont exclues. Le coût des erreurs, l'utilisateur final et l'apport de l'outil sont détaillés dans la fiche d'impact jointe.

2. Données et préparation

PlantVillage (miroir GitHub, images couleur de tomate) contient 16 756 images, soit 16 742 après suppression des doublons exacts. **PlantDoc** (split officiel) fournit 675 images de train et 69 de test pour les 8 classes retenues. Le déséquilibre est marqué : le virus des feuilles jaunes représente 5 357 images dans PlantVillage contre 373 pour la mosaïque. Le test PlantDoc est très petit (6 à 11 images par classe).

Classe	PlantVillage	PlantDoc train	PlantDoc test
bacterial_spot	2 127	101	9
early_blight	1 000	79	9
healthy	1 585	55	8
late_blight	1 901	101	10
leaf_mold	952	85	6
mosaic_virus	373	44	10
septoria	1 771	140	11
yellow_curl_virus	5 357	70	6

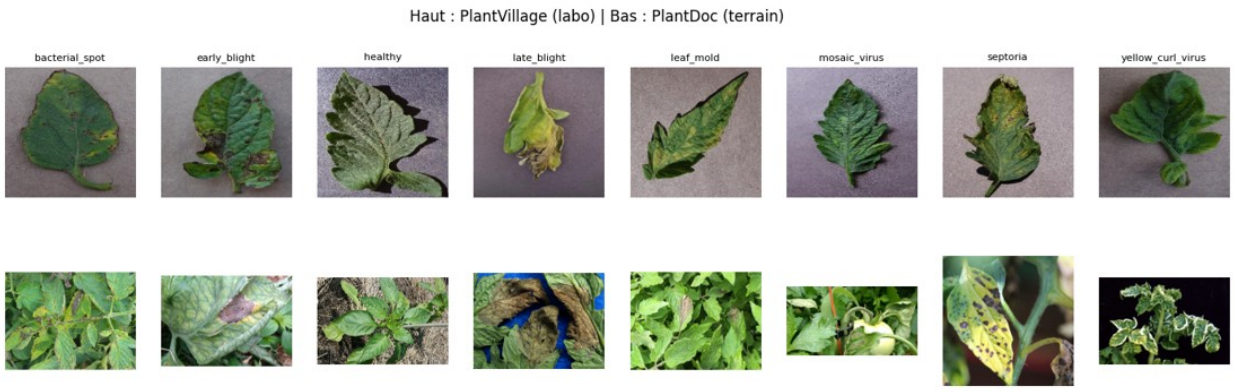


Figure 1. Exemples par classe : PlantVillage (ligne du haut) et PlantDoc (ligne du bas).

Prétraitement. Les images sont redimensionnées en 64×64 pixels et normalisées (division par 255 dans le modèle). Les classes sont pondérées dans la loss pour compenser le déséquilibre. **Découpage sans**

fuite. PlantVillage est découpé de façon stratifiée en 70 % / 15 % / 15 % (10 546 / 2 260 / 2 260 images). Pour PlantDoc, le test officiel (69 images) n'est jamais utilisé pour entraîner ni pour choisir un modèle ; 20 % du train officiel servent de validation (540 train / 135 validation). Les modèles sont choisis sur des jeux de validation, jamais sur le test.

Risque résiduel : PlantVillage contient plusieurs photos d'une même feuille et l'identifiant de la feuille n'est pas disponible. Un découpage aléatoire peut donc placer des photos de la même feuille en train et en test, ce qui gonfle les scores PlantVillage.

3. Modèles et protocole expérimental

- **MLP (baseline)** : images aplaties, Dense 256, Dropout 0,3, Dense 128, softmax. Son rôle est de justifier le CNN.
- **CNN from scratch** : blocs Conv 3×3 (32, 64, 128 filtres), ReLU, MaxPooling, puis global average pooling, Dropout 0,4, Dense 64, softmax. Trois variantes : **A** sans batch normalization, **B** avec batch normalization, **C** avec batch normalization et 2 blocs seulement.
- **Entraînement** : Adam (lr 1e-3), early stopping sur la loss de validation (patience 4, retour aux meilleurs poids), pondération des classes, graine 42, 20 époques maximum pour les modèles de base, 30 pour les stratégies de robustesse.
- **Stratégies de robustesse** : S1 augmentation (flip, rotation, zoom, luminosité, contraste) ; S2 augmentation + changement de fond (les pixels peu saturés des images PlantVillage sont remplacés par des fonds issus du train PlantDoc) ; S3 fine-tuning du modèle S2 sur le train PlantDoc (lr 1e-4) ; S4 entraînement mixte PlantVillage + PlantDoc (PlantDoc sur-échantillonné ×5).

Métrique principale. L'accuracy n'est pas utilisée pour conclure. Nous retenons le **F1 macro** (chaque classe compte autant, malgré le déséquilibre) accompagné du **rappel macro**, et d'un indicateur dédié, **« maladie ratée »** : part des feuilles malades classées « saine ». Ce choix suit le coût des erreurs : une maladie non détectée est plus coûteuse qu'une fausse alerte. Les résultats sont toujours présentés sur laboratoire (PV) ET terrain (PD).

4. Résultats (laboratoire et terrain)

4.1 Baseline MLP et variantes de CNN

Modèle (entraîné sur PV)	F1 macro PV	F1 macro PD	Rappel macro PD	Maladie ratée PD
MLP	0,508	0,059	0,091	0,213
CNN-A (sans BN)	0,872	0,167	0,229	0,000
CNN-B (BN)	0,730	0,154	0,248	0,000
CNN-C (BN, 2 blocs)	0,673	0,183	0,254	0,000

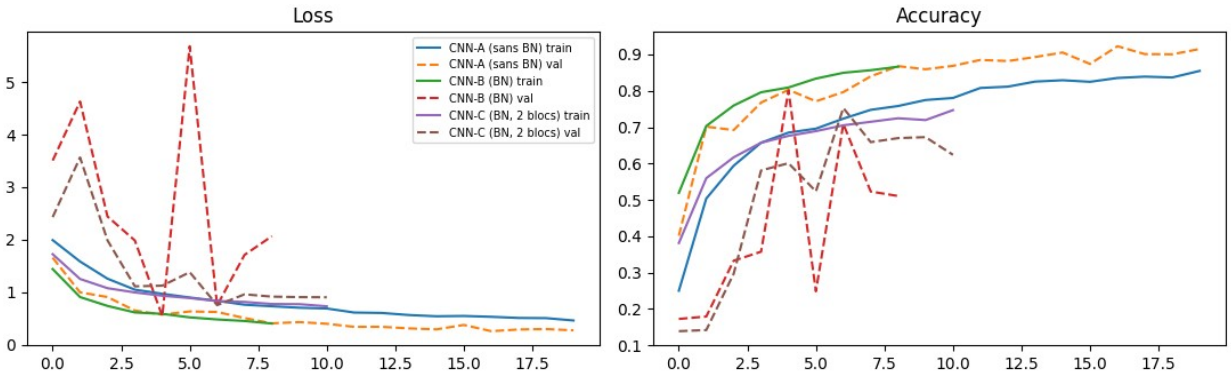


Figure 2. Courbes de loss et d'accuracy des trois variantes de CNN (trait plein : train, pointillés : validation).

Le MLP est insuffisant même sur PlantVillage (F1 macro 0,51) : l'aplatissement détruit la structure spatiale, ce qui justifie le CNN. Le **CNN-A** obtient le meilleur F1 macro sur la validation PlantVillage (0,903 contre 0,749 pour B et 0,685 pour C) et est retenu comme modèle de base.

Surapprentissage. Le CNN-A ne surapprend pas : l'accuracy de validation (0,92) dépasse celle d'entraînement (0,85), car le Dropout et la pondération pénalisent l'entraînement, et la loss de validation décroît encore à l'époque 20. Le modèle est plutôt **sous-entraîné**. Les variantes avec batch normalization présentent une validation très instable (accuracy de validation à 0,17 aux époques 1-2, loss de validation en dents de scie) et ont été arrêtées tôt par l'early stopping (époques 9 et 11). **Attention :** la supériorité du CNN-A sur B et C vient donc en partie de ce protocole d'entraînement (arrêt précoce, un seul essai) et ne prouve pas que la batch normalization est nuisible en général. Une profondeur moindre (C) donne un F1 PlantVillage plus faible que A, ce qui suggère qu'une capacité plus faible limite la performance.

4.2 Le fossé laboratoire / terrain

Le CNN-A passe d'un **F1 macro de 0,872 sur PlantVillage à 0,167 sur PlantDoc**, et d'un rappel macro de 0,892 à 0,229. L'accuracy sur PlantDoc (0,217) est proche du hasard pour 8 classes (0,125). Le MLP s'effondre encore plus (0,508 → 0,059). Le modèle a donc appris à reconnaître des images de laboratoire (fond uniforme, feuille isolée, éclairage contrôlé) plutôt que les symptômes de manière robuste.

À propos de « maladie ratée ». La valeur de 0,000 pour le CNN-A sur PlantDoc ne signifie pas que le modèle est sûr. Elle indique seulement qu'aucune feuille malade n'a été classée saine ; le modèle peut simplement éviter de prédire « saine ». Cet indicateur doit toujours se lire avec la précision, le rappel par classe et le F1 macro.

4.3 Stratégies de réduction de l'écart

Modèle	F1 PV	F1 PD	Rappel PD	Précision PD	Maladie ratée PD
CNN-A (référence)	0,872	0,167	0,229	0,238	0,000
S1 Augmentation	0,720	0,112	0,190	0,088	0,000
S2 Augmentation + fond	0,767	0,228	0,264	0,214	0,115
S3 Fine-tuning sur PlantDoc	0,647	0,310	0,304	0,339	0,049
S4 Entraînement mixte	0,784	0,267	0,320	0,238	0,066

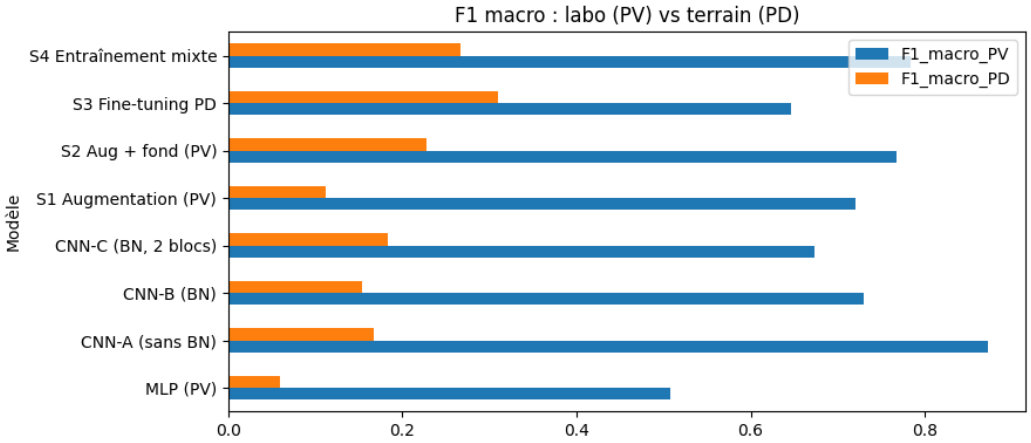


Figure 3. F1 macro sur PlantVillage (laboratoire) et PlantDoc (terrain) pour tous les modèles.

- **S1 (augmentation seule)** n'améliore pas le terrain dans notre configuration (0,112 contre 0,167) et dégrade PlantVillage (0,72). Les transformations géométriques et de luminosité ne changent pas le fond, principal facteur de l'écart, et rendent l'apprentissage plus difficile.

- **S2 (augmentation + changement de fond)** améliore le terrain (0,167 → 0,228) : modifier le fond est plus pertinent que la seule augmentation classique. Mais l'indicateur « maladie ratée » monte à 0,115.
- **S3 (fine-tuning sur PlantDoc)** donne le meilleur F1 terrain (0,310), mais au prix d'un **oubli** du laboratoire : le F1 PlantVillage tombe à 0,647 (0,767 pour S2).
- **S4 (entraînement mixte)** offre le meilleur compromis : 0,784 sur PlantVillage et 0,267 sur PlantDoc, avec le meilleur rappel macro terrain (0,320).

Prudence sur l'interprétation. Le test PlantDoc ne compte que 69 images (6 à 11 par classe) et chaque modèle n'a été entraîné qu'une fois (graine 42). Un écart de quelques centièmes de F1 correspond à une ou deux images ; seules les grandes différences (le fossé 0,87 → 0,17, l'apport des données de terrain) sont fiables. Le classement exact de S2, S3 et S4 ne l'est pas.

5. Analyse des erreurs et explicabilité

Le modèle final est choisi par le F1 macro sur la **validation PlantDoc** : c'est **S3 (fine-tuning)**. Résultats par classe sur le test PlantDoc :

Classe	Précision	Rappel	F1	Support
bacterial_spot	0,33	0,11	0,17	9
early_blight	0,29	0,22	0,25	9
healthy	0,57	0,50	0,53	8
late_blight	0,14	0,30	0,19	10
leaf_mold	0,33	0,33	0,33	6
mosaic_virus	0,11	0,10	0,11	10
septoria	0,44	0,36	0,40	11
yellow_curl_virus	0,50	0,50	0,50	6
Macro	0,34	0,30	0,31	69

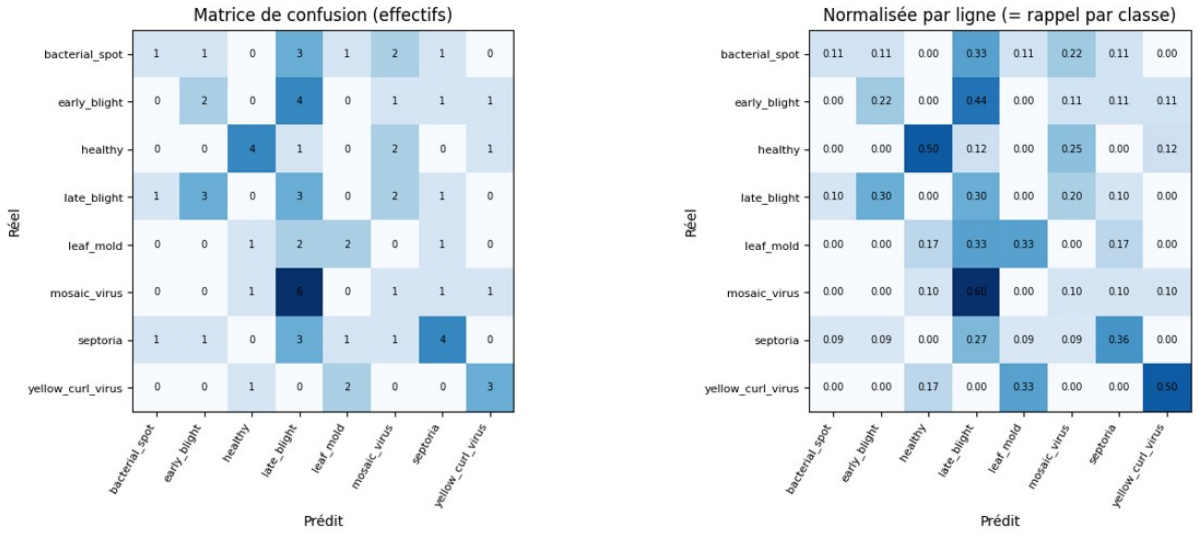


Figure 4. Matrice de confusion du modèle final sur PlantDoc test (effectifs à gauche, rappel par classe à droite).

Lecture de la matrice. La classe **late_blight** joue le rôle d'attracteur : 22 des 69 images sont prédites « mildiou », pour seulement 3 correctes (précision 0,14). Six des dix images de **mosaïque** sont prédites « mildiou » (rappel 0,10, la pire classe). Les classes les mieux reconnues sont la feuille saine et le virus des feuilles jaunes (rappel 0,50), ce qui reste faible. Côté coût des erreurs, **3 feuilles malades sur 61 (4,9 %)** sont classées saines : le risque le plus coûteux est donc limité ici, mais la moitié des feuilles saines (4 sur 8) sont prises pour malades, soit des traitements inutiles.

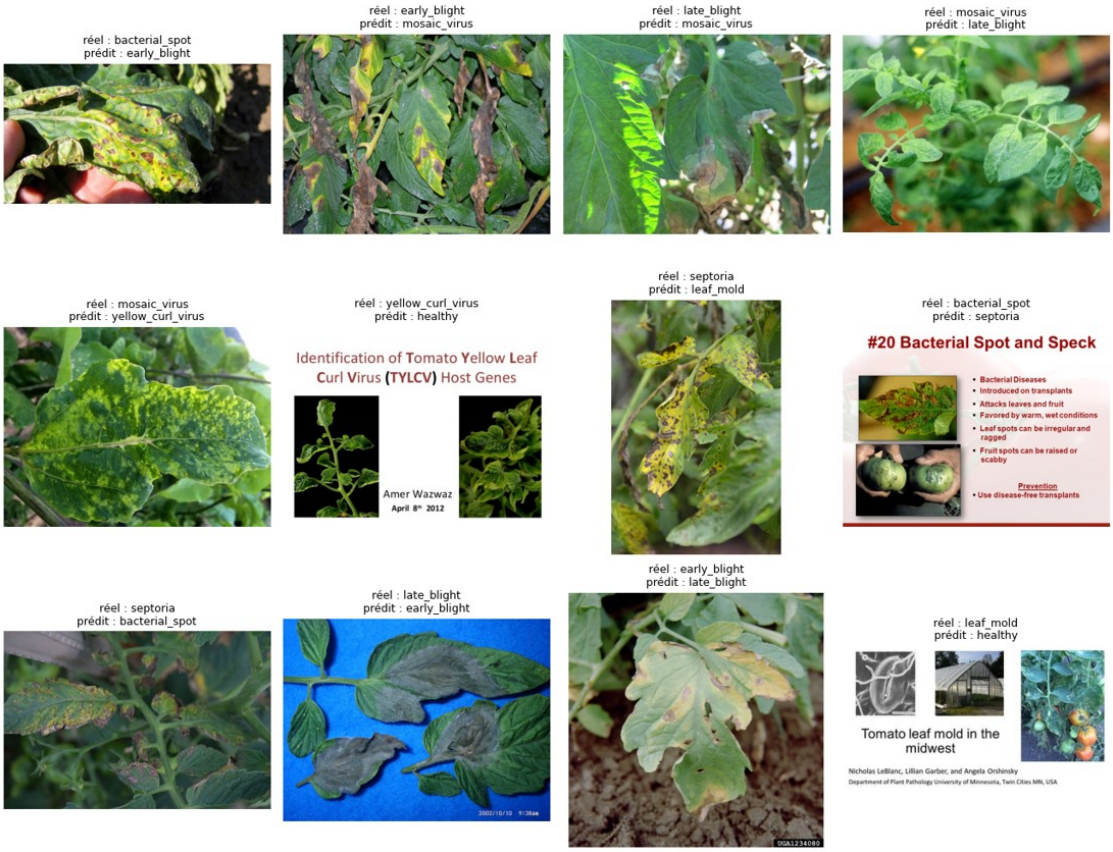


Figure 5. Douze exemples mal classés de PlantDoc test (titre : classe réelle / classe prédite).

Hypothèses sur les causes (à partir des images de la Figure 5) :

- **Images qui ne sont pas des photos de feuille** : trois des douze exemples sont des diapositives ou affiches avec du texte (virus des feuilles jaunes prédit « saine », tache bactérienne prédite « septoriose », moisissure prédite « saine »). Ce sont des artefacts de la collecte web de PlantDoc : l'erreur vient de la donnée, pas du modèle.
- **Symptômes visuellement proches** : alternariose, mildiou, septoriose et tache bactérienne produisent des taches brunes sur fond jaune ; la mosaïque et le virus des feuilles jaunes donnent des feuilles marbrées. À 64×64 pixels, les détails qui les distinguent disparaissent.
- **Lumière et fond** : une zone très éclairée domine l'image dans l'exemple mildiou prédit « mosaïque » ; des photos prises de loin (plante entière, feuillage dense) montrent des lésions minuscules qui se perdent dans le fond.
- **Feuilles partielles ou plusieurs feuilles** : la main au premier plan, les pots et le sol occupent une grande partie de l'image.
- **Peu d'exemples** : 44 images de mosaïque en train PlantDoc et 6 à 11 images par classe en test rendent les rappels très instables.

Grad-CAM : la lésion ou le fond ?

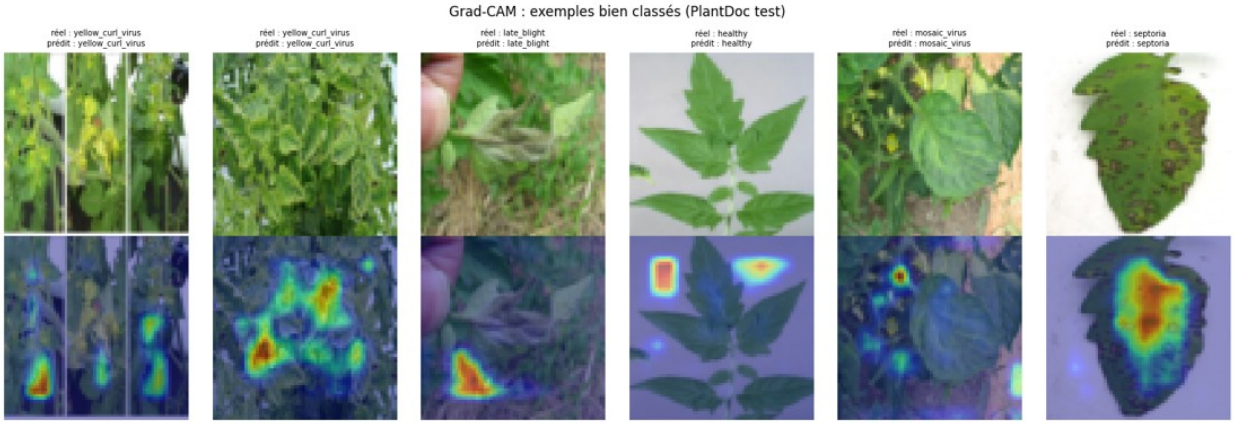


Figure 6. Grad-CAM du modèle final sur des exemples bien classés (ligne du haut : image, ligne du bas : carte d'attention).

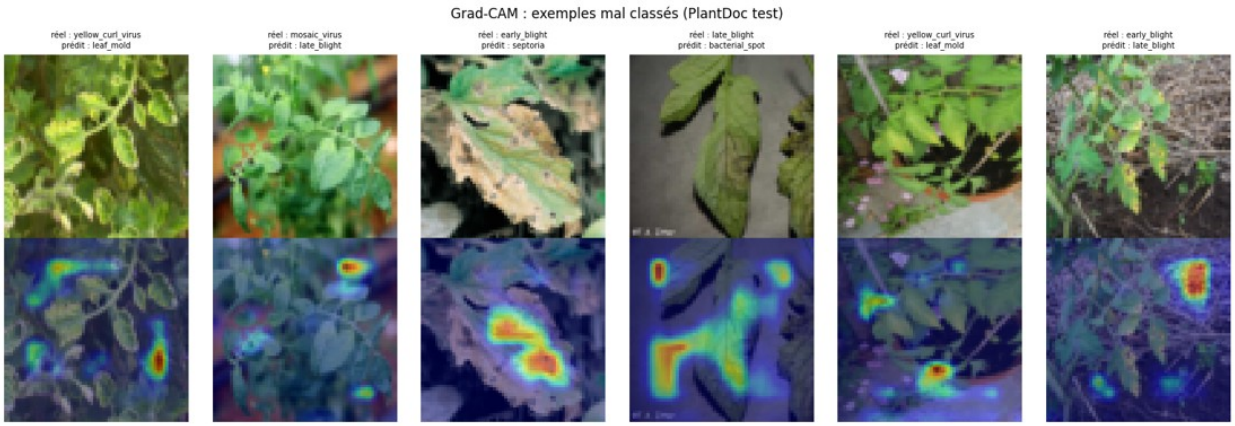


Figure 7. Grad-CAM du modèle final sur des exemples mal classés.

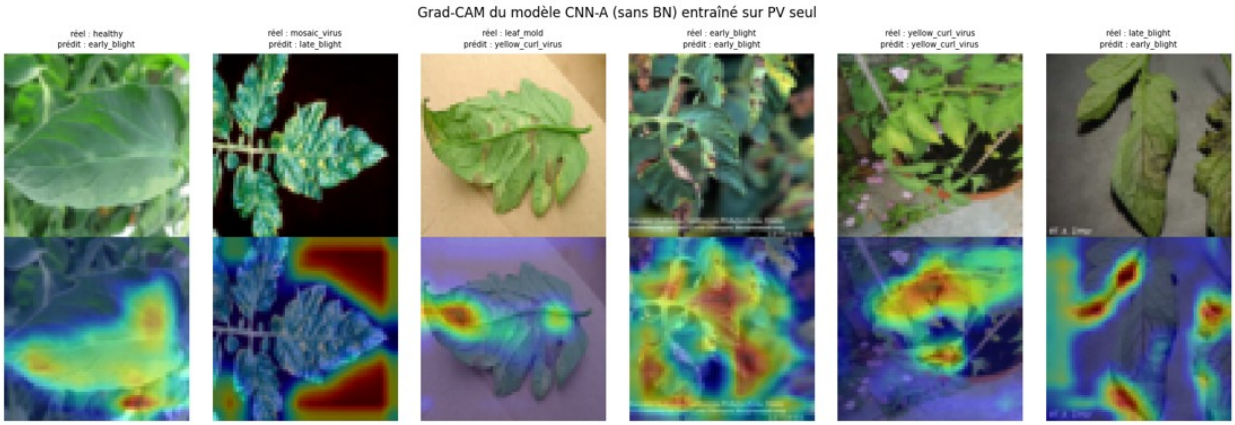


Figure 8. Grad-CAM du modèle CNN-A entraîné sur PlantVillage seul (6 images PlantDoc tirées au hasard).

Observations (qualitatives, sur 6 images par figure). Parmi les exemples bien classés, la carte d'attention se concentre sur les lésions pour la septoriose et sur les zones jaunies pour le virus des feuilles jaunes. En revanche, pour la feuille saine, l'attention porte sur des zones du fond gris plutôt que sur la feuille : la bonne réponse peut venir d'un indice de fond. Pour les exemples mal classés, l'attention se disperse vers le sol, un pot, les bords et un coin de l'image portant un texte parasite, alors que la lésion reste en dehors des zones chaudes. Le modèle entraîné **uniquement sur PlantVillage** (Figure 8) regarde souvent les coins sombres ou le support (carton, bords de l'image) plutôt que la feuille : c'est l'illustration d'un **apprentissage par raccourci**, où le modèle utilise le fond uniforme comme indice de classe. Ces cartes sont calculées sur une grille de 8×8 (images 64×64) ; elles sont donc grossières et les 18 exemples ne constituent pas une preuve statistique.

6. Limites, risques et pistes d'amélioration

Limites techniques

- **Test PlantDoc minuscule** (69 images, 6 à 11 par classe) : les scores par classe sont très bruités et les différences entre stratégies, souvent inférieures à l'incertitude.
- **Une seule graine, un seul essai par modèle** : pas d'intervalle de confiance ; la comparaison A/B/C est biaisée par l'arrêt précoce des variantes avec batch normalization.
- **Résolution 64×64** : perte des détails fins des lésions, cartes Grad-CAM grossières.
- **Fuite possible dans PlantVillage** : plusieurs photos d'une même feuille ; les scores PlantVillage sont probablement optimistes.
- **Changement de fond approximatif** (seuil de saturation) : il peut effacer des parties de feuille pâles ; les fonds viennent du train PlantDoc.
- **Bruit dans PlantDoc** : diapositives et affiches parmi les images de test, étiquettes parfois discutables.
- **Périmètre réduit** : 8 classes ; acariens et target spot exclues ; aucune classe « autre / inconnu ».

Risques pour l'utilisateur

- **Maladie non détectée** : la propagation (mildiou en particulier) peut détruire une parcelle. Ici 4,9 % des feuilles malades sont classées saines pour le modèle final, jusqu'à 11,5 % pour S2 et 21 % pour le MLP.
- **Fausses alertes** : la moitié des feuilles saines sont prises pour malades, donc des traitements inutiles et un coût pour l'agriculteur.
- **Mauvais diagnostic** : avec 29 % d'accuracy sur le terrain, un traitement choisi d'après la prédiction serait le plus souvent inadapté.
- **Surconfiance** : le modèle répond toujours, même pour une feuille hors des 8 classes (carence, autre culture, photo mal cadrée).
- **Biais de couverture** : PlantVillage et PlantDoc ne reflètent pas les variétés, climats et conditions de prise de vue d'un utilisateur local (par exemple au Sénégal).

Pistes d'amélioration

- Collecter des photos locales prises avec des smartphones d'agriculteurs et validées par des experts : c'est la leçon principale de S3 et S4, où les données de terrain apportent le plus.
- Ajouter une réponse « incertain » (seuil de confiance) et une classe « autre ».
- Augmenter la résolution, entraîner plus longtemps, répéter sur plusieurs graines ; découper PlantVillage par feuille quand c'est possible.
- Explorer le transfer learning (non vu en cours) et des augmentations de fond plus réalistes (segmentation de la feuille).

7. Conclusion

Un CNN entraîné uniquement sur PlantVillage atteint un F1 macro de 0,87 au laboratoire mais de **0,17 sur des photos de terrain**, soit un niveau proche du hasard. Le Grad-CAM suggère que ce modèle s'appuie en partie sur le fond. Changer le fond lors de l'entraînement aide (0,23), et ajouter des données de terrain aide davantage (0,27 à 0,31), avec un compromis entre le terrain et le laboratoire. Même le meilleur modèle ne dépasse pas 29 % d'accuracy sur PlantDoc et confond massivement les maladies entre elles. **Ce prototype n'est pas utilisable en l'état pour conseiller un agriculteur** ; le point décisif est l'accès à des données de terrain locales et validées, plus que le choix de l'architecture. Ces conclusions doivent être lues avec la réserve d'un test de 69 images et d'une seule graine.

Références

- Hughes, D. P., & Salathé, M. (2015). An open access repository of images on plant health to enable the development of mobile disease diagnostics (PlantVillage).
- Singh, D. et al. (2020). PlantDoc: A Dataset for Visual Plant Disease Detection. CoDS-COMAD.
- Selvaraju, R. R. et al. (2017). Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization. ICCV.